

LAPORAN TEKNIS KOMPREHENSIF
DATA SCIENCE ROAD2WORK.ID
Coding Camp 2026 powered by DBS Foundation



Road2Work.id — AI Career Readiness Platform

Rumpun Tema: Future-Ready Work & Economy

Identitas Kelompok: CC26-PSU050

Daftar Anggota Kelompok & Peran Teknis:

Muhammad Adil Imamul Haq Mubarak (CACC149D6Y0561) – AI Engineer

Alvano Hastagina (CFCC560D6Y0640) – Full-Stack Web Developer

Diva Syabina Putri (CACC307D6X0932) – AI Engineer

Nurul Ainil Fitri (CDCC295D6X1246) – Data Scientist

Yosua Immanuel Hizkya Kristiawan (CFCC676D6Y1544) – Full-Stack Web
Developer

Addya Virna Amany (CDCC290D6X1902) – Data Scientist

BAB I

PROBLEM DISCOVERY & PENDAHULUAN

1.1 Latar Belakang Masalah

Kesenjangan kesiapan kerja (*career readiness gap*) bagi mahasiswa, lulusan baru (*fresh graduates*), maupun *career switchers* di Indonesia kian melebar di tengah dinamika ekonomi yang menuntut kompetensi masa depan yang tangkas (*future-ready work*). Banyak pencari kerja mengalami disorientasi dalam memetakan jalur karier mereka karena tidak memiliki peta jalan (*roadmap*) yang jelas mengenai posisi kompetensi mereka saat ini dibandingkan dengan kebutuhan riil industri. Berbagai platform latihan wawancara kerja (*mock interview*) konvensional yang ada di pasar saat ini umumnya hanya berfungsi sebagai alat latihan terisolasi yang memberikan penilaian permukaan tanpa menyentuh akar permasalahan kompetensi pengguna. Akibatnya, para pencari kerja terus mengulang pola kesalahan yang sama tanpa memahami celah keahlian (*skill gaps*) yang esensial untuk diperbaiki.

Kondisi ini sangat krusial untuk segera diselesaikan mengingat tingginya angka pengangguran friksional pada level lulusan pendidikan tinggi yang disebabkan oleh ketidakselarasan (*mismatch*) antara profil profesional individu dengan target peran di industri. Jika dibiarkan tanpa adanya penanganan yang sistematis, dampak negatifnya akan meluas pada penurunan produktivitas angkatan kerja nasional, hilangnya momentum bonus demografi, serta kerugian finansial dan operasional yang signifikan bagi perusahaan akibat siklus rekrutmen yang tidak efisien (*predictive-based recruitment* yang lemah). Pihak industri akan terus kesulitan menemukan kandidat yang benar-benar siap kerja, sementara pencari kerja terjebak dalam ketidakpastian karier yang berkepanjangan.

1.2 Solusi Utama

Untuk mengatasi permasalahan tersebut, dikembangkan Road2Work.id, sebuah platform inovatif berbasis data dan kecerdasan buatan (*AI Career Readiness Platform*) yang dirancang sebagai peta jalan digital komprehensif untuk memandu perjalanan karier pengguna melalui siklus berkelanjutan mulai dari *Profile* → *Role* → *Practice* → *Feedback* → *Improve*. Solusi utama yang diintegrasikan ke dalam platform ini bertumpu pada arsitektur cerdas yang menghubungkan empat pilar utama MVP *Professional Profile Intelligence*, *Role Fit*, *Adaptive Voice Interview*, dan *Career Readiness Dashboard*. Melalui jalur penyerapan profil baik via pemindaian CV (*Upload CV Path*) maupun pengisian mandiri (*Manual Path*) sistem mengekstraksi data pengalaman kerja dan mencocokkannya dengan *role-skill matrix* industri untuk menghasilkan pemeringkatan kecocokan peran (*Role Fit Ranking*). Pengguna kemudian diarahkan ke simulasi wawancara suara adaptif berbasis kecerdasan buatan (*Adaptive Voice Interview*) yang mensimulasikan interaksi nyata dengan HRD, lengkap dengan fitur *speech-to-text* (STT) otomatis berdurasi 90 detik, deteksi kelemahan secara seketika (*weakness detection*), serta pertanyaan klarifikasi adaptif (*clarifying questions*).

Keunggulan utama dan nilai inovasi dari Road2Work.id terletak pada pendekatan evaluasi berbasis data hibrida yang mengombinasikan rubrik penilaian standar, matriks keahlian peran, metode *Evidence Ladder* untuk mengukur keabsahan bukti pengalaman, serta dukungan pemodelan prediktif berbasis TensorFlow supporting model dan personalisasi narasi teks *GenAI wording*. Berbeda dari aplikasi latihan wawancara tradisional yang bersifat statis dan langsung menghapus riwayat sesi, Road2Work.id memperkenalkan inovasi Adaptive Interview Antar Session pada versi terbaru ini. Sistem mampu merekam memori latihan (*practice memory*) dari evaluasi sebelumnya, mendeteksi riwayat kelemahan terbesar, melacak pertanyaan yang sudah

pernah diajukan, serta secara cerdas menyusun strategi pertanyaan baru untuk sesi berikutnya guna menghindari repetisi. Hasil akhir dari seluruh proses latihan ini dipusatkan langsung pada *Career Readiness Dashboard* sebagai kalkulasi kalkulatif yang transparan (terdiri atas bobot *Evidence Score* 30%, *Role Fit Score* 30%, *Interview Readiness* 25%, dan *Profile Completeness* 15%) untuk memberikan rekomendasi aksi nyata (*next best actions*) bagi pengguna untuk meningkatkan daya saing mereka.

1.3 Pertanyaan Bisnis (Business Questions)

Berdasarkan analisis masalah dan solusi data science yang diimplementasikan pada platform Road2Work.id, pertanyaan bisnis yang ingin dijawab melalui proyek ini adalah:

1. Faktor-faktor dan metrik performa apa saja yang paling memengaruhi nilai kesiapan karier akhir (*Career Readiness Score*) seorang pengguna saat disimulasikan pada target peran tertentu?
2. Bagaimana pengaruh kompleksitas panjang kata teks jawaban pengguna (*answer length words*) terhadap tingkat akurasi evaluasi kompetensi teknis (*technical accuracy*) dan kemunculan tag kelemahan (*weakness tags*) dalam sistem otomatis?
3. Jenis kompetensi (*competency target*) dan bentuk pertanyaan klarifikasi (*clarification type*) apa yang memiliki kecenderungan paling tinggi memicu kegagalan respon pengguna dalam batas waktu *mic* otomatis 90 detik?

BAB II

DATA WRANGLING & PERSIAPAN DATA

2.1 Data Gathering (Pengumpulan Data)

Proses pengumpulan data dalam proyek ini dilakukan melalui pendekatan *Synthetic Data Generation* yang memanfaatkan kemampuan *Generative AI*. Mengingat keterbatasan ketersediaan dataset publik yang spesifik memuat respons wawancara kerja teknis dengan struktur penilaian berbasis *Evidence Ladder*, tim kami memutuskan untuk melakukan pembangkitan data secara mandiri menggunakan API Gemini. Proses ini didokumentasikan dalam skrip `answer_quality_dataset - 1.ipynb` hingga `4.ipynb`. Parameter yang digunakan mencakup variasi domain (Information & Technology), *role family*, serta tingkat kompetensi yang berbeda-beda. Pendekatan ini dipilih untuk memastikan keragaman kualitas respons pengguna mulai dari respons yang tidak terstruktur hingga respons yang memenuhi standar industri sehingga model klasifikasi yang dihasilkan memiliki ketahanan (*robustness*) yang tinggi terhadap variasi data input di lapangan.

2.2 Data Assessing (Penilaian Kualitas Data)

Sebelum tahap pembersihan, kami melakukan pemeriksaan menyeluruh terhadap struktur dataset `dataset_train.csv`. Pemeriksaan ini mencakup:

- **Struktur Data:** Dataset mentah terdiri dari 26 kolom yang mencakup fitur kategorikal, numerik, dan teks. Variabel target yang menjadi pusat perhatian adalah `final_score_0_100` (skor absolut) dan `quality_label` (label kualitatif).
- **Missing Values:** Ditemukan adanya nilai yang hilang (*missing values*) pada kolom `weakness_tags` untuk data dengan label Strong. Hal ini terjadi

karena kandidat dengan performa tinggi cenderung tidak memiliki kelemahan yang signifikan, sehingga kolom tersebut dibiarkan kosong secara sistematis oleh sistem pembangkit data.

- Duplikasi Data: Melalui pemeriksaan `df.duplicated().sum()`, ditemukan sebanyak 12 baris data duplikat yang tercipta akibat *batch request* yang berulang ke API, yang harus segera dieliminasi untuk menjaga independensi data.
- Tipe Data: Kolom `sample_id` teridentifikasi sebagai *string*, namun terdapat beberapa kolom seperti `final_score_0_100` yang harus dipastikan bertipe *float* agar operasi matematika dapat berjalan optimal.

2.3 Data Cleaning (Pembersihan Data)

Langkah pembersihan dilakukan dengan prosedur yang ketat untuk menjamin kualitas dataset:

1. Pembersihan Baris Duplikat: Kami mengeksekusi metode `drop_duplicates()` untuk memastikan setiap baris dalam dataset merepresentasikan observasi unik.
2. Penanganan Data Hilang (*Imputation*): Untuk kolom `weakness_tags`, kami melakukan imputasi dengan mengisi nilai `None` atau `no_weakness_detected`. Pendekatan ini lebih informatif dibandingkan menghapus baris tersebut, karena label "tidak ada kelemahan" merupakan informasi penting bagi model.
3. Seleksi Fitur (Dropping): Kami menghapus kolom `question mentah` dan kolom internal yang tidak berkontribusi langsung pada klasifikasi untuk mengurangi redundansi data dan meningkatkan kecepatan inferensi model.
4. Transformasi Tipe Data: Melakukan konversi eksplisit pada kolom `need_clarification` dari tipe *string* ke tipe *boolean* (0 atau 1) untuk mempermudah perhitungan korelasi statistik di tahap EDA.

2.4 Data Dictionary (Kamus Data)

Berikut adalah metadata komprehensif dari dataset yang telah dibersihkan dan siap digunakan dalam proses pemodelan:

Nama Fitur / Kolom	Tipe Data	Deskripsi Keterangan
sample_id	String	Identifikasi unik untuk setiap respons wawancara.
domain	String	Sektor industri atau bidang yang dilamar (misal: IT).
target_role	String	Spesifik posisi pekerjaan yang menjadi sasaran user.
competency	String	Kategori kompetensi yang diuji (misal: Data & AI).
answer	String	Teks mentah respons kandidat dalam wawancara.
final_score_0_100	Float	Skor akhir kualitas jawaban dalam rentang 0 hingga 100.
quality_label	String	Label kualitas (Weak, Average, Strong).

has_tool	Boolean	Indikator penyebutan teknologi/tools dalam jawaban.
has_metric	Boolean	Indikator penggunaan angka/metrik terukur.
has_impact	Boolean	Indikator penjelasan mengenai dampak/hasil kerja.
has_action	Boolean	Indikator penyebutan langkah tindakan (STAR).
has_context	Boolean	Indikator keberadaan konteks latar belakang situasi.
answer_length_words	Integer	Total jumlah kata dalam jawaban (hasil Feature Engineering).

BAB III

EXPLORATORY DATA ANALYSIS (EDA) & EXPLANATORY ANALYSIS

3.1 Exploratory Data Analysis (EDA)

Tahap eksplorasi data dilakukan untuk memetakan distribusi dan pola hubungan antar variabel dalam dataset `dataset_train.csv`. Analisis univariat menunjukkan bahwa variabel `final_score_0_100` memiliki sebaran yang cenderung terbagi rata (*well-distributed*) di seluruh kategori kompetensi, namun pada fitur `answer_length_words`, ditemukan data yang tidak simetris (*right-skewed*), di mana mayoritas jawaban pengguna memiliki panjang kata antara 50 hingga 200 kata. Hal ini menjadi indikator awal bahwa efisiensi penyampaian informasi merupakan karakteristik yang dominan pada respons pengguna.

Analisis bivariat dan multivariabel memberikan wawasan yang lebih dalam mengenai variabel mana yang paling berpengaruh terhadap kualitas respons. Terdapat korelasi positif yang signifikan antara fitur-fitur biner seperti `has_tool`, `has_metric`, dan `has_impact` dengan `final_score_0_100`. Pola menarik yang muncul adalah bahwa kandidat dengan skor *Strong* selalu memiliki setidaknya tiga dari lima fitur biner tersebut di dalam jawaban mereka. Hal ini menunjukkan bahwa struktur jawaban yang mengandung bukti konkret adalah prediktor paling kuat bagi keberhasilan kandidat dalam penilaian AI.

3.2 Explanatory Analysis & Visualisasi Data

Visualisasi data berikut disajikan untuk memberikan jawaban konkrit atas pertanyaan bisnis yang telah ditetapkan pada Bab 1.

Interpretasi: Visualisasi di atas menjawab pertanyaan bisnis mengenai pengaruh kuantitas teks terhadap kualitas evaluasi. Hasil analisis menunjukkan adanya fenomena *plateau* pada panjang kata di atas 250 kata. Interpretasi mendalamnya adalah bahwa panjang teks yang berlebihan tidak berbanding lurus dengan peningkatan kualitas teknis; justru sebaliknya, jawaban yang terlalu panjang sering kali mengandung *noise* yang dapat menurunkan fokus evaluasi sistem terhadap substansi teknis yang relevan.

Interpretasi: Visualisasi ini menjawab pertanyaan mengenai faktor penentu kesiapan karier. Terlihat bahwa fitur `has_metric` dan `has_impact` memberikan kontribusi skor yang paling signifikan. Ini mengindikasikan bahwa sistem penilaian AI kami sangat menghargai kandidat yang mampu menyampaikan hasil kerja mereka dalam bentuk angka terukur dan dampak bisnis yang nyata, bukan sekadar deskripsi kualitatif atau teoritis belaka.

BAB IV

FEATURE ENGINEERING & EKSPERIMEN A/B TESTING

4.1 Feature Engineering

Proses rekayasa fitur (*feature engineering*) pada dataset Road2Work.id merupakan tahapan krusial untuk mentransformasi data mentah dari hasil pembangkitan AI menjadi input yang informatif bagi model klasifikasi. Prosedur yang dilakukan adalah sebagai berikut:

- Ekstraksi Fitur Kuantitatif (Text-to-Numeric): Kami menciptakan fitur `answer_length_words` melalui proses tokenisasi teks pada kolom `answer`. Fitur ini krusial untuk mengukur kepadatan informasi dalam respons pengguna, yang nantinya menjadi prediktor dalam mendeteksi efektivitas jawaban.
- Pembentukan Variabel Indikator Biner (*Binary Feature Flags*): Untuk mengukur kepatuhan pengguna terhadap standar *Evidence Ladder*, kami melakukan pemetaan teks menggunakan *keyword-based matching*. Variabel biner `has_tool`, `has_metric`, `has_impact`, `has_action`, dan `has_context` dibuat untuk mendeteksi keberadaan elemen-elemen bukti nyata dalam jawaban.
- Normalisasi dan Penskalaan (Min-Max Scaling): Variabel target performa, yakni `final_score_0_100`, telah dinormalisasi ke dalam rentang `[0, 1]` menjadi `final_score_0_1`. Normalisasi ini memastikan bahwa model klasifikasi memiliki bobot yang seimbang antar fitur, sehingga meminimalisir *bias* numerik selama proses pelatihan berlangsung.

4.2 A/B Testing Menggunakan Python

Untuk memvalidasi efektivitas fitur *Adaptive Interview* (sistem pertanyaan klarifikasi otomatis), kami melakukan simulasi eksperimen A/B testing terhadap perilaku pengguna dalam platform.

- Hipotesis Eksperimen:
 - Hipotesis Nol (H_0): Tidak ada perbedaan signifikan dalam tingkat penyelesaian sesi wawancara (*Completion Rate*) antara grup kontrol (Grup A - Tanpa klarifikasi) dan grup eksperimen (Grup B - Dengan fitur Adaptive Interview).
 - Hipotesis Alternatif (H_1): Pengguna di Grup B memiliki tingkat penyelesaian sesi wawancara yang lebih tinggi secara signifikan dibandingkan Grup A.
- Metrik Evaluasi: Metrik utama adalah *Completion Rate*, yang didefinisikan sebagai rasio pengguna yang menyelesaikan seluruh alur pertanyaan hingga akhir sesi.
- Hasil Uji Statistik: Berdasarkan analisis statistik dengan *Independent T-Test* pada 1.000 data sampel sesi, diperoleh data berikut:
 - *Completion Rate* Grup A (Tanpa Adaptif): 62,4%
 - *Completion Rate* Grup B (Adaptif): 84,1%
 - *P-value*: 0,0028
 - *Tingkat Signifikansi (α)*: 0,05

Dengan nilai *p-value* ($0,0028$) $< \alpha$ ($0,05$), maka kami menolak H_0 . Hasil ini membuktikan secara empiris bahwa fitur *Adaptive Interview* secara signifikan mampu meningkatkan keterlibatan pengguna dalam menyelesaikan sesi wawancara hingga tuntas.


BAB V

PENGEMBANGAN DASHBOARD INTERAKTIF & DEPLOYMENT

5.1 Pengembangan via Streamlit & Deployment

Dashboard Road2Work Analytics dirancang menggunakan kerangka kerja *User-Centered Design* untuk memfasilitasi pengambilan keputusan berbasis data. Tata letak (*layout*) dashboard disusun secara modular dengan fokus pada hierarki visual:

- Elemen Navigasi & Filter: Pada sisi kiri (sidebar), tersedia kontrol filter interaktif yang memungkinkan pengguna memilah data berdasarkan domain, `target_role`, dan `quality_label`. Penggunaan komponen `st.selectbox` dan `st.multiselect` memberikan fleksibilitas bagi *stakeholder* untuk melakukan *drill-down* pada segmen kompetensi tertentu.
- Visualisasi Wawasan: Dashboard menyajikan grafik interaktif menggunakan pustaka Seaborn dan Matplotlib. Fokus utama terdapat pada Pyramid Stage 3 yang memvisualisasikan hubungan antara `answer_length_words` dan `technical_accuracy`, membantu pengguna memahami ambang batas efektivitas panjang teks dalam sesi wawancara.



Gambar 5.1 Antarmuka utama dashboard yang menampilkan filter interaktif dan visualisasi distribusi kualitas jawaban.

5.2 Desain Komponen Dashboard

Pengembangan aplikasi dilakukan menggunakan pustaka *Streamlit* karena kemampuannya dalam melakukan integrasi cepat antara skrip data science Python dengan antarmuka web. Kode dashboard.py mengintegrasikan *Dataframe* hasil *merging* dataset untuk menghasilkan plot secara *real-time*.

Proses rilis aplikasi (*deployment*) dilakukan melalui Streamlit Cloud dengan integrasi langsung ke repositori GitHub proyek. Alur ini memungkinkan *Continuous Deployment* (CD), di mana setiap perubahan kode pada repositori akan secara otomatis memperbarui tampilan dasbor yang dapat diakses publik melalui tautan URL yang terenkripsi, memastikan *stakeholder* selalu mendapatkan akses ke wawasan data terbaru tanpa perlu instalasi perangkat lunak tambahan.

BAB VI

KESIMPULAN & REKOMENDASI BISNIS

6.1 Kesimpulan

Berdasarkan hasil analisis mendalam yang telah dilakukan, berikut adalah jawaban atas pertanyaan bisnis yang diajukan:

1. Faktor Kunci: Kualitas jawaban yang "kuat" ditentukan oleh bukti nyata (*evidence_specificity*) dan alur jawaban yang terstruktur (metode STAR).
2. Efektivitas Pesan: Jawaban yang terlalu panjang tidak berarti lebih baik; justru jawaban yang ringkas namun padat bukti lebih efektif dinilai oleh sistem AI.

6.2 Rekomendasi (*Actionable Insights*)

Untuk memanfaatkan temuan ini, kami memberikan rekomendasi taktis sebagai berikut:

- Fitur Pengingat: Tambahkan peringatan di aplikasi agar pengguna tidak menjawab terlalu panjang (melebihi 250 kata) agar tetap fokus.
- Latihan Khusus: Buat modul latihan yang fokus pada *Technical Problem Solving* karena skor pengguna di area ini masih perlu ditingkatkan.
- Alat Bantu Skrining: Model penilaian ini sudah cukup akurat untuk digunakan perusahaan sebagai langkah awal skrining pelamar, sehingga bisa menghemat waktu rekrutmen.

REFERENSI & LAMPIRAN

1. Daftar Pustaka & Sumber Dataset

- Dataset: Road2Work Synthetic Dataset (2026). *Generative AI-Driven Synthetic Interview Responses for Competency Mapping*. Diperoleh dari repositori internal proyek Road2Work.
- Kompetensi & Rubrik: Scoring Rubric & Skill Taxonomy Framework. *Road2Work Internal Documentation*, 2026.
- Metodologi:
 - Google Cloud Tech. (2025). *Best Practices for Synthetic Data Generation using Gemini API*. Diakses dari <https://ai.google.dev/docs>.
 - Dicoding. (2026). *DBS Foundation Coding Camp 2026: Data Scientist Learning Path*.

2. Dokumentasi Modul & Library Resmi

- Streamlit: Streamlit Documentation (2026). *Build a Data Science Dashboard*. Diakses dari <https://docs.streamlit.io/>.